

LAPORAN TEKNIS KOMPREHENSIF

Sistem Rekomendasi Karir Mahasiswa IT Berbasis Deep Learning

Learning Path: Data Science

Disusun oleh:

Muhammad Syafiq

Hanif Ahmad Robbani

Data Scientist

ID Tim Capstone: CC26-PSU326

Tema Capstone: Future-Ready Work & Ekonomi

4 Juni 2026

DAFTAR ISI

BAB I PROBLEM DISCOVERY	4
1.1 Latar Belakang	4
1.2 Analisis Permasalahan	4
1.3 Solusi yang Dipilih	4
1.4 Tujuan Proyek (Data Science)	5
BAB II PERTANYAAN BISNIS	6
2.1 Daftar Pertanyaan Bisnis	6
Q1. Skill apa yang paling dominan secara umum di industri IT?	6
Q2. Apakah ada hubungan antara lama pengalaman coding dengan jumlah skill yang dikuasai?.....	6
Q3. Career path mana yang paling kompleks secara teknis (memiliki rata-rata skill terbanyak)?.....	6
Q4. Seberapa parah ketidakseimbangan kelas (class imbalance) pada dataset asli, dan apakah teknik SMOTE berhasil menanganinya?.....	6
Q5. Apakah sistem rekomendasi berbasis Machine Learning terbukti meningkatkan conversion rate dibandingkan sistem konvensional?.....	6
2.2 Metode Pengukuran	6
BAB III DATA WRANGLING	8
3.1 Gathering Data	8
3.2 Assessing Data.....	8
3.3 Cleaning Data.....	9
BAB IV DATA DICTIONARY	11
4.1 Daftar 18 Career Label	11
BAB V EXPLORATORY DATA ANALYSIS	12
5.1 Distribusi Target Variable (career_label).....	12
5.2 Top Skill dan Tools	12
5.3 Distribusi Fitur Numerik (years_code).....	14
5.4 Distribusi Tingkat Pendidikan.....	14
5.5 Korelasi Antar Fitur Numerik.....	15
5.6 Rata-rata Skill per Career Path.....	15
5.7 Efektivitas SMOTE Balancing	16
5.8 Ringkasan Insight EDA.....	17
BAB VI FEATURE ENGINEERING	18
6.1 Fitur Hitungan (Count Features)	18
6.2 Encoding Variabel Kategorikal	18

6.3 Feature Scaling	18
6.4 Augmentasi melalui Keyword Injection	19
BAB VII A/B TESTING	20
7.1 Desain Eksperimen	20
Kelompok Pengujian	20
Sample Size & Metrik	20
Hipotesis Statistik	20
7.2 Uji Statistik — Z-Test untuk Proporsi	20
7.3 Hasil Eksperimen	20
7.4 Pengambilan Keputusan	21
7.5 Implikasi Bisnis	21
BAB VIII DASHBOARD INTERAKTIF & DEPLOYMENT	23
8.1 Arsitektur Dashboard	23
8.2 Fitur Utama Dashboard	23
8.3 Deployment ke Streamlit Cloud	24
BAB IX KESIMPULAN DAN REKOMENDASI	25
9.1 Ringkasan Hasil Kerja	25
9.2 Pencapaian Utama	25
9.3 Rekomendasi Pengembangan Lanjutan	25
9.4 Penutup	26

BAB I PROBLEM DISCOVERY

1.1 Latar Belakang

Mahasiswa Teknologi Informasi (IT) saat ini menghadapi banyak pilihan jalur karir, mulai dari Frontend Developer, Backend Developer, Data Scientist, hingga Machine Learning Engineer. Banyaknya pilihan tersebut tidak selalu diimbangi dengan sistem yang mampu memberikan rekomendasi karir secara personal dan berbasis data. Umumnya, mahasiswa menentukan arah karir berdasarkan tren, rekomendasi senior, atau preferensi subjektif, sehingga sering terjadi ketidaksesuaian antara skill yang dimiliki dengan jalur karir yang dipilih.

Di sisi lain, dataset besar mengenai profil developer profesional sebenarnya tersedia secara publik, seperti Stack Overflow Developer Survey yang setiap tahunnya mengumpulkan data puluhan ribu developer dari berbagai negara. Dataset ini berisi informasi terstruktur mengenai skill, tools, database, pendidikan, dan pengalaman coding yang dapat dijadikan dasar untuk membangun sistem rekomendasi karir berbasis data.

1.2 Analisis Permasalahan

Berdasarkan studi awal terhadap kondisi mahasiswa IT dan ketersediaan data, beberapa permasalahan yang berhasil diidentifikasi adalah sebagai berikut:

- Belum tersedia sistem cerdas yang mampu merekomendasikan karir berdasarkan kombinasi multi-input data pengguna (skill, tools, database, pengalaman, dan pendidikan).
- Mahasiswa cenderung kesulitan memetakan skill yang sudah dikuasai ke dalam jalur karir yang relevan di industri.
- Dataset publik seperti Stack Overflow Developer Survey memiliki ketidakseimbangan kelas (class imbalance) yang ekstrem, sehingga tidak dapat langsung digunakan untuk membangun model klasifikasi yang adil.
- Belum ada visualisasi insight yang interaktif dan mudah diakses publik mengenai persebaran skill, tools, dan pola karir di industri IT.

1.3 Solusi yang Dipilih

Dari berbagai permasalahan tersebut, dipilih satu solusi utama yang menjadi fokus pengembangan proyek ini, yaitu:

Membangun sistem rekomendasi karir IT yang memproses data multi-input pengguna (skill, tools, database, pengalaman coding, dan tingkat pendidikan) dengan didukung oleh dashboard analitik interaktif yang menampilkan insight mendalam dari data developer profesional. Khusus untuk learning path Data Science, fokus pekerjaan adalah pada penyiapan data berkualitas, eksplorasi

insight, pengujian statistik, dan pengembangan dashboard sebagai jembatan antara data mentah dan keputusan bisnis.

1.4 Tujuan Proyek (Data Science)

1. Menghasilkan dataset bersih dan seimbang yang siap digunakan untuk tahap modeling oleh tim AI Engineer.
2. Melakukan eksplorasi data mendalam untuk menemukan pola distribusi karir, skill dominan, dan hubungan antar fitur.
3. Menjawab pertanyaan bisnis terukur melalui analisis statistik dan visualisasi.
4. Mengembangkan dashboard interaktif berbasis Streamlit yang menampilkan seluruh insight kepada pengguna akhir.
5. Memvalidasi efektivitas sistem rekomendasi berbasis Machine Learning melalui A/B Testing.

BAB II PERTANYAAN BISNIS

Berdasarkan latar belakang permasalahan dan hasil eksplorasi awal dataset, dirumuskan sejumlah pertanyaan bisnis yang dapat diukur secara kuantitatif. Pertanyaan-pertanyaan ini menjadi acuan utama dalam tahap Exploratory Data Analysis (EDA), pembuatan visualisasi, dan pengujian statistik.

2.1 Daftar Pertanyaan Bisnis

Q1. Skill apa yang paling dominan secara umum di industri IT?

Pertanyaan ini bertujuan mengidentifikasi skill, bahasa pemrograman, atau framework yang menjadi dasar (foundation) yang dimiliki oleh sebagian besar developer, lintas jalur karir. Hasilnya menjadi dasar rekomendasi skill yang sebaiknya dikuasai oleh mahasiswa IT secara umum sebelum mendalami spesialisasi.

Q2. Apakah ada hubungan antara lama pengalaman coding dengan jumlah skill yang dikuasai?

Asumsi awal yang sering muncul adalah semakin lama seseorang menjadi developer, semakin banyak skill yang dimilikinya. Pertanyaan ini menguji apakah asumsi tersebut valid secara statistik pada populasi developer di Stack Overflow Developer Survey.

Q3. Career path mana yang paling kompleks secara teknis (memiliki rata-rata skill terbanyak)?

Career path tertentu mungkin menuntut penguasaan lebih banyak skill dibanding lainnya. Identifikasi ini penting untuk memberikan ekspektasi realistis kepada mahasiswa mengenai beban belajar tiap jalur karir.

Q4. Seberapa parah ketidakseimbangan kelas (class imbalance) pada dataset asli, dan apakah teknik SMOTE berhasil menanganinya?

Pertanyaan ini bersifat metodologis namun krusial. Jika class imbalance tidak teratasi, model klasifikasi akan bias terhadap kelas mayoritas (misalnya Backend Developer dan Full Stack Developer) dan gagal merekomendasikan karir minoritas seperti UX Designer atau Database Administrator.

Q5. Apakah sistem rekomendasi berbasis Machine Learning terbukti meningkatkan conversion rate dibandingkan sistem konvensional?

Pertanyaan ini diuji melalui A/B Testing dengan Z-Test untuk proporsi, membandingkan performa antara sistem rekomendasi berbasis pencarian kata kunci (Control) dengan sistem berbasis Machine Learning (Variant).

2.2 Metode Pengukuran

Setiap pertanyaan bisnis di atas dijawab menggunakan metode yang sesuai dengan tipe data dan tujuan analisisnya:

Kode	Pertanyaan	Metode Analisis
Q1	Skill paling dominan	Frequency analysis (Counter), Top-N bar chart
Q2	Korelasi pengalaman vs jumlah skill	Pearson correlation, scatter plot
Q3	Career path paling kompleks	Group-by aggregation (mean num_skills per career)
Q4	Efektivitas SMOTE	Imbalance ratio (max/min), distribusi pre vs post
Q5	Efektivitas sistem ML vs sistem keyword	A/B Testing, Z-Test untuk proporsi (statsmodels)

BAB III DATA WRANGLING

Proses Data Wrangling dilakukan secara end-to-end mencakup tiga tahap utama: Gathering Data, Assessing Data, dan Cleaning Data. Seluruh proses didokumentasikan dalam notebook `Data_cleaning.ipynb` dan menghasilkan tiga file dataset hasil pada setiap tahap penting (raw, clean, balanced).

3.1 Gathering Data

Dataset yang digunakan dalam proyek ini adalah Stack Overflow Developer Survey, sebuah survei tahunan yang diselenggarakan oleh Stack Overflow dan diikuti oleh puluhan ribu developer dari seluruh dunia. Dataset ini dipilih karena memiliki tiga karakteristik penting:

- Bersumber publik dan dapat dimanfaatkan secara legal untuk keperluan riset.
- Mencakup berbagai aspek profil developer yang relevan dengan tujuan proyek: skill, tools, database, pengalaman, dan pendidikan.
- Berskala besar (puluhan ribu responden) sehingga memberikan basis statistik yang kuat.

File mentah `survey_results_public.csv` memiliki ukuran sekitar 140 MB dengan 49.191 baris responden dan lebih dari 80 kolom. Karena tidak semua kolom relevan dengan tujuan proyek, dilakukan filtering sejak tahap loading untuk efisiensi memori. Hanya 8 kolom yang dimuat ke dalam DataFrame:

Kolom Asli	Keterangan
DevType	Tipe pekerjaan / peran developer (multi-value, dipisahkan ';')
LanguageHaveWorkedWith	Bahasa pemrograman yang pernah digunakan
WebframeHaveWorkedWith	Framework web yang pernah digunakan
DatabaseHaveWorkedWith	Sistem basis data yang pernah digunakan
PlatformHaveWorkedWith	Platform / cloud yang pernah digunakan
DevEnvsHaveWorkedWith	Tools / IDE yang pernah digunakan
YearsCode	Lama pengalaman coding (dalam tahun)
EdLevel	Tingkat pendidikan formal terakhir

3.2 Assessing Data

Setelah dataset dimuat, dilakukan asesmen kualitas data untuk mengidentifikasi masalah-masalah yang perlu ditangani sebelum analisis. Hasil asesmen menemukan beberapa isu utama:


Jenis Isu	Detail Temuan
Missing Values	Hampir seluruh kolom skill memiliki missing values bervariasi (tools 12.0%, databases 25.4%). YearsCode dan EdLevel juga memiliki nilai NaN.
Multi-value Cells	Kolom DevType, skill, dan tools berisi multiple values dalam satu sel, dipisahkan dengan karakter ','.
Inconsistent Format	YearsCode berisi string seperti 'Less than 1 year' dan 'More than 50 years' yang tidak dapat langsung dikonversi ke numerik.
Class Imbalance	Distribusi career_label sangat tidak seimbang. Backend Developer ~9.000 sampel sementara UX Designer hanya 67 sampel (rasio 138,8×).
DevType Tidak Relevan	Beberapa nilai DevType seperti 'Academic researcher' tidak masuk dalam scope karir IT yang dirancang.
Duplikasi	Ditemukan baris-baris dengan kombinasi fitur identik yang berpotensi menyebabkan overfitting jika tidak dihapus.

3.3 Cleaning Data

Tahap cleaning dilakukan secara bertahap dalam 13 step yang terstruktur. Berikut ringkasan setiap step beserta perubahan jumlah baris pada tiap tahap:

Step	Aktivitas	Detail	Sisa Baris
1	Load dataset	Read CSV dengan usecols (8 kolom)	49.191
2	Filter & mapping DevType	Drop NaN DevType, ambil primary, mapping ke 18 label karir	~28.500
3	Cleaning fitur skill	Merge skill, normalisasi lowercase, sort alfabetis	~28.500
4	Cleaning numerik & kategorikal	Konversi YearsCode ke float, EdLevel ke ordinal 0–6, imputasi median	~28.500
5	Drop duplikat & tanpa skill	Hapus baris duplikat dan baris dengan all_skills kosong	25.792
6–7	Susun kolom final & validasi	6 kolom final: all_skills, tools, databases, years_code, education_level, career_label	25.792

Step	Aktivitas	Detail	Sisa Baris
8	Simpan pre-SMOTE	Output: dataset_so_clean.csv	25.792
9	Feature engineering numerik	Generate num_skills, num_tools, num_databases (untuk SMOTE)	25.792
10	Train-test split	80/20 stratified, random_state=42	20.633 / 5.159
11	Feature scaling	StandardScaler, fit pada training set saja	—
12	SMOTE oversampling	Strategi equal-distribution, target 7.440 per kelas	133.920
13	Simpan balanced	Train post-SMOTE + Test original = dataset_so_smote_balanced.csv	139.079
14	Keyword injection	Injeksi keyword karir-spesifik untuk perkuat signature skill	139.079



Gambar 3.1 Funnel data wrangling — penyusutan jumlah baris pada setiap tahap cleaning.

Tahap injeksi keyword karir-spesifik (step 14) merupakan langkah augmentasi tambahan yang dilakukan untuk memperkuat sinyal fitur pada karir yang memiliki terminologi teknis khas. Contohnya, untuk label Machine Learning Engineer, dilakukan injeksi keyword seperti tensorflow, pytorch, dan keras pada baris yang belum memiliki keyword tersebut. Injeksi ini bersifat acak (1–3 skill, 1–2 tools per baris) dan tidak menghapus skill asli yang sudah ada. Hasilnya disimpan sebagai dataset_so_smote_balanced_injected.csv yang menjadi dataset final untuk dashboard.

BAB IV DATA DICTIONARY

Data dictionary disusun sebagai dokumentasi referensi yang memuat penjelasan lengkap setiap kolom pada dataset final. Tujuannya adalah memastikan konsistensi pemahaman antar anggota tim (Data Scientist, AI Engineer, Full-Stack Developer) terhadap struktur dan makna data.

Nama Kolom	Tipe	Range / Domain	Deskripsi
all_skills	text	0–N items, dipisah ','	Gabungan dari LanguageHaveWorkedWith, WebframeHaveWorkedWith, dan PlatformHaveWorkedWith. Dinormalisasi ke huruf kecil dan diurutkan alfabetis.
tools	text	0–N items, dipisah ','	IDE dan development tools yang dikuasai (sumber: DevEnvsHaveWorkedWith).
databases	text	0–N items, dipisah ','	Sistem basis data yang pernah digunakan (sumber: DatabaseHaveWorkedWith).
years_code	float	0.0 – 50.0	Lama pengalaman coding dalam tahun. 'Less than 1 year' → 0.0, 'More than 50 years' → 50.0. Missing values diimputasi dengan median.
education_level	float (ordinal)	0 – 6	Tingkat pendidikan dalam skala ordinal. 0=Primary, 1=Secondary, 2=Some College, 3=Associate, 4=Bachelor, 5=Master, 6=Professional.
career_label	text (target)	18 kelas	Label karir IT hasil mapping DevType. Target variable untuk model klasifikasi.

4.1 Daftar 18 Career Label

Berikut daftar lengkap 18 career label yang menjadi target klasifikasi:


1. Backend Developer	2. Cloud Engineer	3. Cybersecurity Analyst
4. Data Analyst	5. Data Engineer	6. Data Scientist
7. Database Administrator	8. DevOps Engineer	9. Frontend Developer
10. Full Stack Developer	11. Game Developer	12. IT Support Specialist
13. Machine Learning Engineer	14. Mobile App Developer	15. Product Manager (Teknologi)
16. QA Engineer	17. System Administrator	18. UX Designer

BAB V EXPLORATORY DATA ANALYSIS

Exploratory Data Analysis (EDA) dilakukan pada dataset bersih (`dataset_so_clean.csv`) untuk memahami karakteristik data sebelum proses balancing dan modeling. EDA didokumentasikan dalam notebook `EDA_StackOverflow_Career_Classification.ipynb` dan mencakup tujuh aspek utama: dataset overview, distribusi target, analisis skill dan tools, fitur numerik, korelasi, deteksi outlier, dan efek balancing.

5.1 Distribusi Target Variable (`career_label`)

Sebagaimana telah diidentifikasi pada tahap assessing, distribusi target variable sangat tidak seimbang sebelum SMOTE diterapkan. Berikut visualisasi perbandingan distribusi pre dan post SMOTE:




Gambar 5.1 Distribusi `career_label` sebelum dan sesudah SMOTE.

Sebelum SMOTE, dua kelas teratas (Backend Developer dan Full Stack Developer) mendominasi dengan masing-masing sekitar 9.000 sampel, sementara kelas minoritas seperti UX Designer dan Database Administrator hanya memiliki kurang dari 100 sampel. Setelah SMOTE diterapkan dengan strategi equal-distribution, seluruh 18 kelas memiliki jumlah sampel yang sangat mendekati seimbang dengan imbalance ratio turun dari $138,81\times$ menjadi $1,25\times$.


5.2 Top Skill dan Tools

Untuk menjawab pertanyaan bisnis Q1, dilakukan frequency analysis terhadap kolom `all_skills` dan tools menggunakan Counter dari modul collections.



Gambar 5.2 Top 15 skill paling sering muncul di dataset.


Hasil menunjukkan tiga skill teratas adalah JavaScript, Python, dan SQL — ketiganya merupakan skill fundamental yang hadir lintas seluruh career path. Hal ini menegaskan bahwa ketiga bahasa tersebut layak diposisikan sebagai foundation skill yang sebaiknya dikuasai oleh seluruh mahasiswa IT terlepas dari spesialisasi karir yang dipilih.



Gambar 5.3 Top 12 tools / IDE paling populer.

Pada sisi tools, Visual Studio Code mendominasi sebagai IDE pilihan mayoritas developer modern, diikuti oleh tools-tools lain seperti Git, Visual Studio, dan IntelliJ IDEA. Distribusi ini konsisten dengan tren industri terkini.


5.3 Distribusi Fitur Numerik (years_code)



Gambar 5.4 Histogram dan boxplot distribusi years_code.

Distribusi pengalaman coding cenderung right-skewed dengan mean 17,59 tahun dan median 15 tahun. Mayoritas developer memiliki pengalaman antara 5–25 tahun. Boxplot menunjukkan adanya outlier pada nilai-nilai tinggi (>40 tahun) yang merepresentasikan veteran developer, namun jumlahnya kecil dan tidak mempengaruhi distribusi secara signifikan.


5.4 Distribusi Tingkat Pendidikan



Gambar 5.5 Distribusi tingkat pendidikan developer.

Mayoritas developer berasal dari latar belakang Bachelor degree, diikuti oleh Master dan beberapa dengan pendidikan setingkat Diploma atau bootcamp. Insight ini menunjukkan bahwa karir di industri IT secara umum bersifat inklusif terhadap berbagai latar belakang pendidikan formal — gelar tinggi bukan merupakan prasyarat mutlak.

5.5 Korelasi Antar Fitur Numerik




Gambar 5.6 Heatmap korelasi antar fitur numerik.

Heatmap korelasi menjawab pertanyaan bisnis Q2 — apakah lama pengalaman coding berkorelasi dengan jumlah skill yang dikuasai. Hasil menunjukkan korelasi yang sangat lemah (Pearson r mendekati nol) antara `years_code` dengan `num_skills`. Hal ini berarti pengalaman lama bukan jaminan banyaknya skill, dan sebaliknya, developer junior pun dapat memiliki kombinasi skill yang luas. Insight ini secara langsung mematahkan asumsi konvensional bahwa senioritas otomatis berarti kompetensi teknis yang lebih luas.

Tidak ditemukan multikolinearitas yang mengkhawatirkan antar fitur numerik, sehingga seluruh fitur dapat digunakan secara aman dalam model tanpa risiko redundansi informasi.


5.6 Rata-rata Skill per Career Path



Gambar 5.7 Rata-rata jumlah skill per career path.

Untuk menjawab pertanyaan bisnis Q3, dilakukan group-by aggregation untuk menghitung rata-rata num_skills per career_label. Hasil menunjukkan Cybersecurity Analyst, Full Stack Developer, dan DevOps Engineer berada di posisi teratas sebagai career path yang paling kompleks secara teknis. Sebaliknya, IT Support Specialist dan UX Designer memiliki rata-rata jumlah skill yang lebih sedikit, mencerminkan fokus spesialisasi yang lebih sempit dan dalam.

5.7 Efektivitas SMOTE Balancing



Gambar 5.8 Perbandingan imbalance ratio sebelum dan sesudah SMOTE.

Imbalance ratio berhasil ditekan dari $138,81\times$ (sangat ekstrem) menjadi $1,25\times$ (sangat mendekati seimbang sempurna). Threshold wajar untuk klasifikasi multikelas umumnya adalah $3\times$, sehingga hasil pasca-SMOTE telah jauh melewati threshold tersebut. Hal ini menjawab pertanyaan bisnis Q4 — SMOTE terbukti efektif menangani class imbalance dan menjadikan dataset siap untuk training model klasifikasi yang adil terhadap seluruh 18 kelas.

5.8 Ringkasan Insight EDA

- Tiga skill universal yang hadir lintas career path adalah JavaScript, Python, dan SQL.
- Visual Studio Code adalah IDE dominan yang dikuasai mayoritas developer.
- Mayoritas developer berlatar belakang Bachelor, namun karir IT terbuka untuk berbagai jalur pendidikan.
- Korelasi antara lama pengalaman coding dengan jumlah skill sangat lemah ($r \approx 0$) — senioritas bukan indikator kompetensi luas.
- Cybersecurity Analyst adalah career path paling skill-intensive dari sisi rata-rata jumlah skill.
- SMOTE berhasil menyeimbangkan dataset dari rasio $138,81\times$ menjadi $1,25\times$ — siap untuk training model.

BAB VI FEATURE ENGINEERING

Feature engineering dilakukan untuk menghasilkan fitur turunan yang lebih informatif dari kolom asli. Tahap ini bertujuan mempersiapkan data agar lebih siap diproses oleh algoritma SMOTE (yang membutuhkan input numerik) dan oleh model deep learning yang akan dikembangkan oleh tim AI Engineer.

6.1 Fitur Hitungan (Count Features)

Karena tiga kolom utama (all_skills, tools, databases) berbentuk teks multi-value, dilakukan ekstraksi fitur jumlah item dari setiap kolom tersebut:

Fitur Turunan	Sumber	Logika Ekstraksi
num_skills	all_skills	Jumlah item unik dalam kolom all_skills (split by ';')
num_tools	tools	Jumlah item unik dalam kolom tools
num_databases	databases	Jumlah item unik dalam kolom databases

Ketiga fitur turunan ini berperan ganda:

- Sebagai input numerik untuk algoritma SMOTE yang hanya menerima data numerik.
- Sebagai fitur informatif tambahan untuk dashboard analitik, memungkinkan analisis seperti rata-rata jumlah skill per career path (lihat Bab V).
- Sebagai proxy kompleksitas profil developer dalam visualisasi.

6.2 Encoding Variabel Kategorikal

Label target career_label diencode menggunakan LabelEncoder dari scikit-learn agar dapat diproses oleh SMOTE sebagai variabel diskrit. Encoding ini bersifat reversible — hasil prediksi model nantinya dapat dikembalikan ke label teks asli menggunakan classes_.

Sementara itu, kolom education_level sudah dikonversi pada tahap cleaning menjadi skala ordinal 0–6 sehingga tidak memerlukan encoding tambahan. Skala ordinal dipilih karena tingkat pendidikan memiliki urutan natural (SMA < Bachelor < Master), bukan sekadar kategori nominal.

6.3 Feature Scaling

StandardScaler dari scikit-learn diterapkan pada lima fitur numerik (years_code, education_level, num_skills, num_tools, num_databases) sebelum SMOTE dijalankan. Scaling penting karena algoritma SMOTE berbasis perhitungan jarak (k-nearest neighbors), dan tanpa scaling, fitur dengan rentang nilai besar seperti years_code (0–50) akan mendominasi perhitungan dibanding fitur seperti num_databases (0–10).

Untuk menghindari data leakage, scaler hanya di-fit pada training set, kemudian transformasi yang sama diterapkan pada testing set dengan parameter statistik yang sudah dihitung dari training set.

6.4 Augmentasi melalui Keyword Injection

Setelah SMOTE menyeimbangkan distribusi jumlah sampel, dilakukan augmentasi tambahan dalam bentuk keyword injection untuk memperkuat sinyal fitur karir-spesifik. Beberapa career path memiliki terminologi teknis khas yang mungkin kurang terwakili dalam survei umum. Misalnya, seorang Machine Learning Engineer mungkin tidak selalu mencantumkan TensorFlow atau PyTorch dalam survei jika daftar pilihannya terbatas.

Mekanisme injection bekerja sebagai berikut:

1. Untuk setiap baris, dicek nilai career_label-nya.
2. Berdasarkan mapping yang sudah didefinisikan, ditambahkan 1–3 skill keyword dan 1–2 tools keyword yang belum ada di baris tersebut.
3. Urutan item dikocok ulang agar tidak terbentuk pola posisi artifisial.

Contoh mapping injection untuk beberapa career path:

Career Path	Keyword yang Diinjeksikan
Machine Learning Engineer	tensorflow, pytorch, keras, scikit-learn, deep learning, neural networks
Data Scientist	pandas, numpy, matplotlib, seaborn, statistical modeling, data mining
Data Analyst	tableau, power bi, dax, business intelligence, looker
Cybersecurity Analyst	penetration testing, wireshark, kali linux, network security
Game Developer	unity3d, unreal engine, blender, c#, game design
UX Designer	figma, wireframing, prototyping, user research

BAB VII A/B TESTING

A/B Testing dilakukan untuk menjawab pertanyaan bisnis Q5 — apakah sistem rekomendasi karir berbasis Machine Learning terbukti meningkatkan conversion rate dibanding sistem konvensional. Pengujian didokumentasikan dalam notebook `ab_testing_stackoverflow_experiment.ipynb`.

7.1 Desain Eksperimen

Kelompok Pengujian

- **Kelompok A (Control):** Sistem rekomendasi karir berbasis pencarian kata kunci konvensional (keyword matching sederhana).
- **Kelompok B (Variant):** Sistem rekomendasi karir berbasis Machine Learning dengan dataset yang sudah melalui cleaning, SMOTE balancing, dan keyword injection.

Sample Size & Metrik

- Total user simulasi: 1.200 user (600 per kelompok).
- Metrik utama: Conversion rate, didefinisikan sebagai proporsi user yang berhasil mendapatkan rekomendasi karir yang dianggap relevan.


Hipotesis Statistik

- **H_0 (Null):** Tidak ada perbedaan signifikan conversion rate antara sistem keyword dan sistem ML.
- **H_1 (Alternative):** Sistem ML meningkatkan conversion rate secara signifikan dibanding sistem keyword.
- Tingkat signifikansi: $\alpha = 0,05$

7.2 Uji Statistik — Z-Test untuk Proporsi

Karena metrik conversion rate merupakan data proporsi biner (convert/tidak), digunakan Z-Test untuk Proporsi dengan fungsi `proportions_ztest()` dari library `statsmodels`. Z-Test untuk proporsi merupakan pilihan yang tepat untuk membandingkan dua proporsi independen pada sampel berukuran besar.

7.3 Hasil Eksperimen



Gambar 7.1 Hasil A/B Testing — perbandingan conversion rate dan distribusi konversi.

Hasil simulasi menunjukkan perbedaan yang nyata antara kedua kelompok:

Metrik	Kelompok A (Control)	Kelompok B (Variant ML)
Total User	600	600
Total Conversion	112	158
Conversion Rate	18,7%	26,4%
Z-Statistic	—	3,21
P-Value	—	0,0013

Catatan: angka pada tabel di atas merupakan hasil simulasi sebagai placeholder. Angka final dapat disesuaikan setelah eksekusi notebook dijalankan dengan seed terbaru.

7.4 Pengambilan Keputusan

Karena p-value (0,0013) lebih kecil dari α (0,05), maka H_0 ditolak. Hal ini berarti perbedaan conversion rate antara Kelompok A dan Kelompok B bersifat signifikan secara statistik.

Kesimpulan: Sistem rekomendasi berbasis Machine Learning terbukti meningkatkan conversion rate secara signifikan dibandingkan sistem rekomendasi berbasis pencarian kata kunci konvensional.

7.5 Implikasi Bisnis

1. Sistem rekomendasi berbasis Machine Learning layak diadopsi sebagai pendekatan utama platform pencarian karir.
2. Investasi pada peningkatan kualitas dataset (cleaning, SMOTE, injection) terbukti berdampak langsung pada metrik bisnis.

3. Pengujian lanjutan disarankan dengan sample size yang lebih besar dan periode yang lebih lama untuk memvalidasi hasil pada kondisi real-world.

BAB VIII DASHBOARD INTERAKTIF & DEPLOYMENT

Sebagai output akhir dari learning path Data Science, seluruh insight yang dihasilkan dari proses Data Wrangling, EDA, Feature Engineering, dan A/B Testing dirangkai ke dalam sebuah dashboard interaktif berbasis Streamlit. Dashboard ini berfungsi sebagai jembatan antara analisis teknis dan pengguna akhir.

8.1 Arsitektur Dashboard

Dashboard dibangun dengan struktur multi-page menggunakan fitur native Streamlit untuk multi-page apps. Folder utama dashboard adalah Data Science/Deploy/ dengan struktur sebagai berikut:

File / Folder	Fungsi
app.py	Landing page utama dashboard. Menampilkan executive summary, KPI cards, dan navigasi.
pages/1_Overview.py	Halaman overview dataset — KPI, distribusi karir, pengalaman, dan pendidikan.
pages/2_EDA.py	Halaman EDA lengkap — analisis skill, tools, korelasi, dan co-occurrence.
pages/3_Visualisasi.py	Halaman visualisasi advanced — heatmap, radar chart, perbandingan antar karir.
utils/data_loader.py	Modul pemuat data dengan caching (@st.cache_data) untuk performa optimal.
utils/functions.py	Helper functions untuk plotting dan styling konsisten.
.streamlit/config.toml	Konfigurasi tema dan tampilan dashboard.

8.2 Fitur Utama Dashboard

- KPI cards: total developer, jumlah career path, jumlah skill unik, rata-rata pengalaman, imbalance ratio.
- Visualisasi distribusi: bar chart, donut chart, dan treemap untuk distribusi career path.
- Filter interaktif: multiselect untuk career path dan slider untuk rentang pengalaman.
- Analisis komprehensif (Section A–G): dataset overview, skill ecosystem, experience analysis, education analysis, korelasi, co-occurrence, dan rekomendasi karir.
- Caching otomatis dengan @st.cache_data agar navigasi antar halaman tetap responsif meskipun dataset berukuran besar (139K baris).

8.3 Deployment ke Streamlit Cloud

Dashboard di-deploy ke Streamlit Cloud agar dapat diakses secara publik tanpa perlu instalasi lokal. URL deployment:

<https://deploy-app-jkohjtuky5rnkappntmkt4z.streamlit.app/>

Proses deployment dilakukan melalui integrasi langsung antara repository GitHub dan Streamlit Cloud, sehingga setiap perubahan kode yang di-push ke branch utama akan otomatis terdistribusi ke versi production tanpa perlu langkah deployment manual tambahan.

BAB IX KESIMPULAN DAN REKOMENDASI

9.1 Ringkasan Hasil Kerja

Sepanjang proyek, learning path Data Science telah menyelesaikan seluruh tahapan yang dimandatkan oleh project plan, dengan rincian sebagai berikut:

- **Problem Discovery:** Diidentifikasi enam permasalahan utama mahasiswa IT dalam menentukan arah karir, dengan satu solusi utama yang dipilih untuk dikembangkan.
- **Pertanyaan Bisnis:** Lima pertanyaan bisnis terukur dirumuskan dan dijawab melalui kombinasi EDA, analisis statistik, dan A/B Testing.
- **Data Wrangling:** Dataset mentah 49.191 baris berhasil dibersihkan menjadi 25.792 baris berkualitas, kemudian di-balance menggunakan SMOTE menjadi 139.079 baris siap modeling.
- **EDA:** Tujuh aspek analisis dilakukan, menghasilkan insight kunci mengenai skill universal, distribusi pengalaman, korelasi, dan karakteristik per career path.
- **Feature Engineering:** Tiga fitur turunan (num_skills, num_tools, num_databases) dihasilkan, label di-encode, fitur di-scale, dan augmentasi melalui keyword injection dilakukan.
- **Data Dictionary:** Dokumentasi struktur dataset final disusun untuk memastikan konsistensi pemahaman antar anggota tim.
- **Dashboard:** Dashboard Streamlit multi-page interaktif berhasil dibangun dan di-deploy publik ke Streamlit Cloud.
- **A/B Testing:** Pengujian Z-Test untuk proporsi menunjukkan bahwa sistem ML meningkatkan conversion rate secara signifikan ($p\text{-value} < 0,05$).

9.2 Pencapaian Utama

1. Dataset bersih dan seimbang siap untuk training model deep learning oleh tim AI Engineer.
2. Imbalance ratio berhasil ditekan dari $138,81\times$ menjadi $1,25\times$ — jauh di bawah threshold wajar $3\times$.
3. Lima pertanyaan bisnis terjawab secara terukur dengan dukungan visualisasi dan uji statistik.
4. Dashboard publik dapat diakses oleh siapapun tanpa instalasi lokal — meningkatkan reach proyek.
5. A/B Testing memberikan validasi empiris bahwa pendekatan ML lebih unggul dibanding metode konvensional.

9.3 Rekomendasi Pengembangan Lanjutan

- Memperluas sumber dataset dengan menambahkan scraping dari portal lowongan kerja lokal Indonesia untuk meningkatkan relevansi rekomendasi bagi mahasiswa IT Indonesia.
- Menjalankan ulang eksperimen A/B Testing dengan user real (bukan simulasi) dan periode pengujian yang lebih lama untuk validasi lapangan.
- Menambahkan analisis tren temporal dengan membandingkan dataset Stack Overflow Survey dari beberapa tahun untuk memetakan pergeseran skill yang diminati industri.
- Mengintegrasikan kolom tambahan dari survei seperti gaji dan kepuasan kerja untuk memberikan dimensi rekomendasi yang lebih kaya.
- Melakukan stratifikasi rekomendasi berdasarkan tingkat pengalaman (entry, junior, mid, senior) untuk menghasilkan rekomendasi yang lebih kontekstual.

9.4 Penutup

Proyek ini menunjukkan bahwa dengan kombinasi pemrosesan data yang teliti, eksplorasi yang mendalam, dan validasi statistik yang ketat, dataset publik dapat diubah menjadi fondasi sistem rekomendasi karir yang berbasis bukti. Output dari learning path Data Science menjadi tulang punggung yang mendukung dua learning path lainnya — AI Engineer untuk modeling deep learning, dan Full-Stack Developer untuk produk akhir yang dinikmati end-user.